

# Modelado de la Influencia de la Variabilidad de Frecuencia Cardíaca en la Turbulencia del Ciclo Cardíaco

O Barquero Pérez, S. Cantero, R Goya Esteban,  
JL Rojo Álvarez, A García Alberola

Universidad Rey Juan Carlos  
Departamento de Teoría de la Señal y Comunicaciones



December 1, 2017

# Contents

1 1. Introducción

2 2. Métodos

3 3. Database

4 4. Results

5 5. Conclusiones & Trabajo Futuro

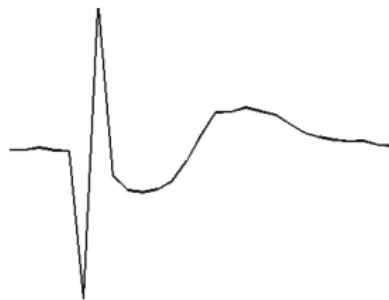
# Introducción

## Contexto

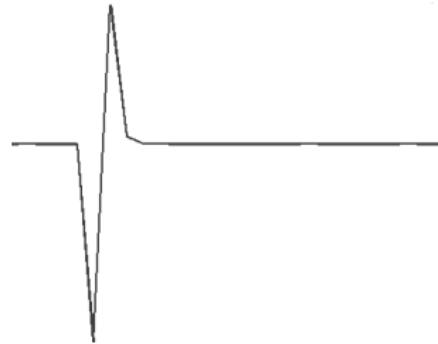
- **Turbulencia del Ciclo Cardíaco** (Heart Rate Turbulence, **HRT**) es la respuesta del nodo sinusal a una contracción ventricular prematura (Ventricular Premature Contraction, **VPC**).
- Consiste en una aceleración inicial del ciclo cardíaco, seguido de una deceleración.

# Introducción

- Healthy subjects



- Paciente con alto riesgo.

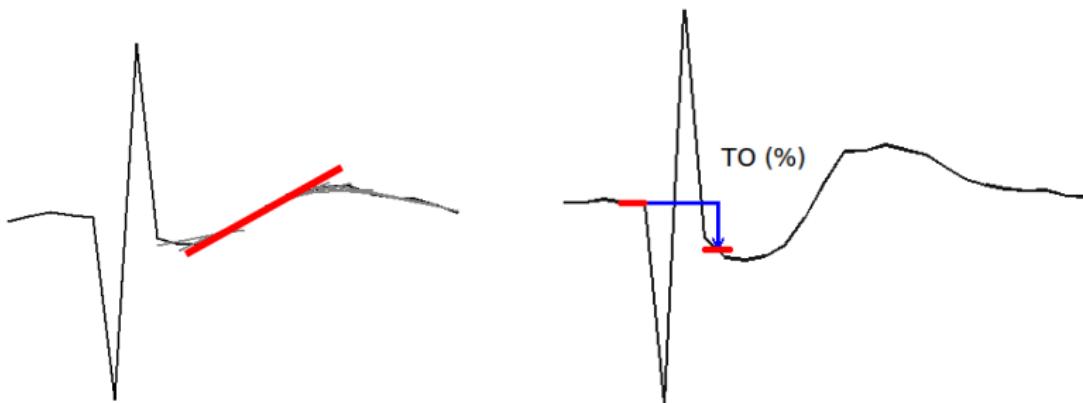


- **HRT** permite identificar paciente con **alto riesgo** de muerte súbita cardíaca.

# Introducción

## Contexto – HRT Caracterización

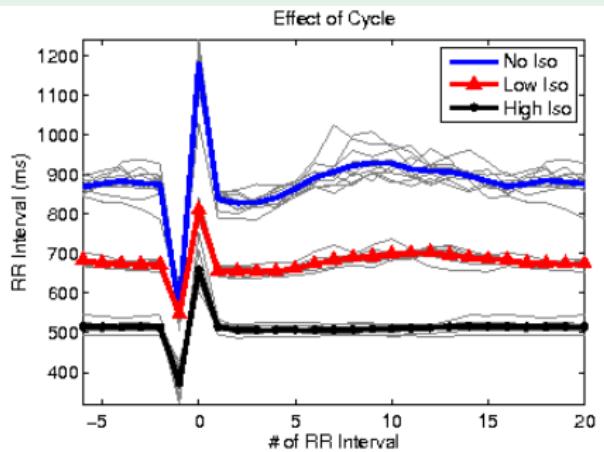
- Es necesario construir un *tacograma promedio*, a partir de aquellos considerados válidos.
- **Turbulence Slope**: máxima pendiente positiva de la regresión lineal sobre cualquier grupo de 5 intervalos RR dentro los 15 primeros a partir del VPC.
- **Turbulence Onset**: diferencia porcentual entre el ritmo cardíaco justo después y después del VPC.



# Introducción

## Factores que afectan HRt

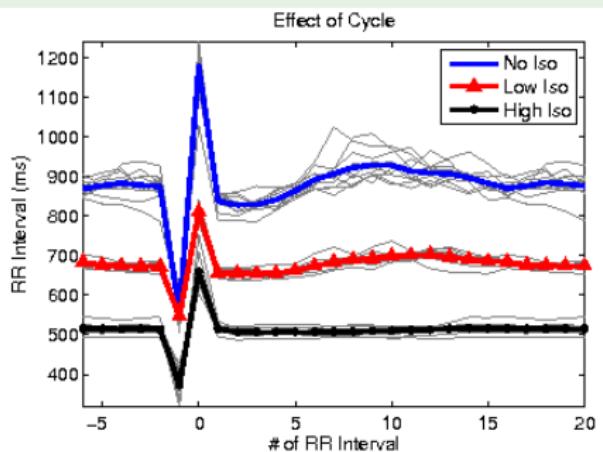
- **Edad:** Envejecimiento está asociado con una reducción de HRT.



# Introducción

## Factores que afectan HRT

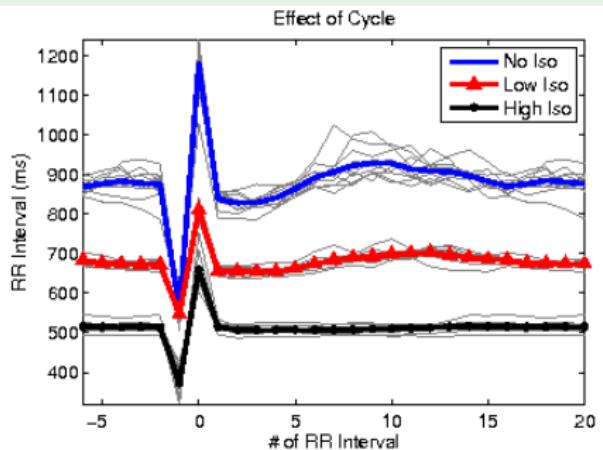
- **Edad:** Envejecimiento está asociado con una reducción de HRT.
- **Ritmo cardíaco:** HRT se reduce en altos ritmos cardíacos.



# Introducción

## Factores que afectan HRT

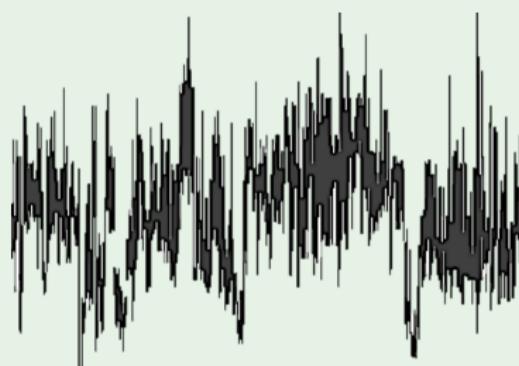
- **Edad:** Envejecimiento está asociado con una reducción de HRT.
- **Ritmo cardíaco:** HRT se reduce en altos ritmos cardíacos.
- **Prematuridad del VPC:** Origen baroreflexa del HRT



# Introducción

## HRV caracterización

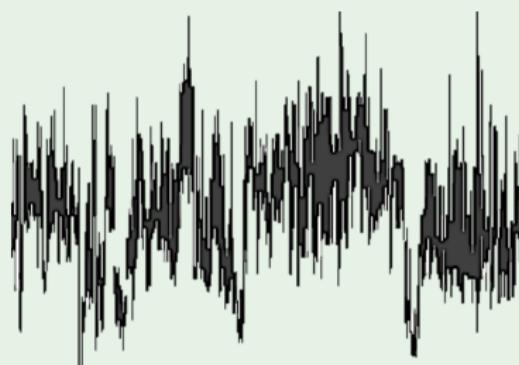
- Existe una relación entre **Variabilidad de Frecuencia Cardíaca (Heart Rate Variability, HRV)** y **HRT**.



# Introducción

## HRV caracterización

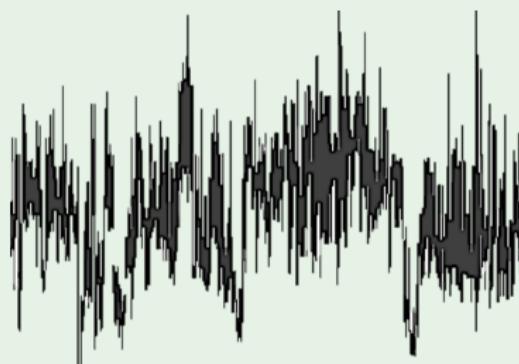
- Existe una relación entre **Variabilidad de Frecuencia Cardíaca (Heart Rate Variability, HRV)** y **HRT**.
- **HRV**: refleja la regulación del Sistema Nervioso Autónomo (SNA) sobre el Ritmo Cardíaco.



# Introducción

## HRV caracterización

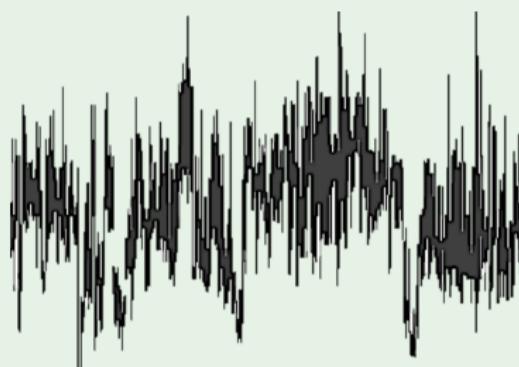
- Existe una relación entre **Variabilidad de Frecuencia Cardíaca (Heart Rate Variability, HRV)** y **HRT**.
- **HRV**: refleja la regulación del Sistema Nervioso Autónomo (SNA) sobre el Ritmo Cardíaco.
- **HRV**: es un potente predictor de paciente en alto riesgo cardíaco.



# Introducción

## HRV caracterización

- Existe una relación entre **Variabilidad de Frecuencia Cardíaca (Heart Rate Variability, HRV)** y **HRT**.
- **HRV**: refleja la regulación del Sistema Nervioso Autónomo (SNA) sobre el Ritmo Cardíaco.
- **HRV**: es un potente predictor de paciente en alto riesgo cardíaco.
- Se ha demostrado que existe una relación entre **HRT** y **HRV** sobre Holters de 24 horas ⇒ Ambos están bajo la influencia del **SNA**.



# Objetivos del trabajo

- 1 Proponer una modelo no-paramétrico de **HRT** como función de la **HRV** utilizando **Boosted Regression Trees, BRT**.

# Objetivos del trabajo

- ① Proponer una modelo no-paramétrico de **HRT** como función de la **HRV** utilizando **Boosted Regression Trees, BRT**.
- ② Estudiar la relación entre **HRT** and **HRV** en pacientes que han sufrido **Infarto de Miocardio** utilizando el **modelo propuesto**.

# Contents

1 1. Introducción

2 2. Métodos

3 3. Database

4 4. Results

5 5. Conclusiones & Trabajo Futuro

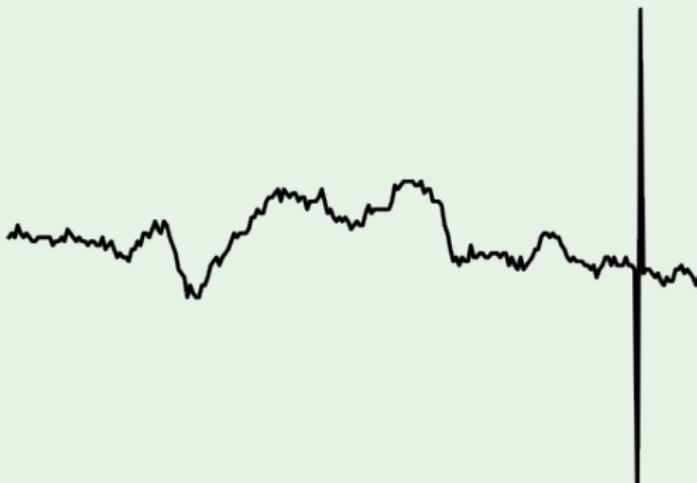
# Métodos

## HRT Boosted Regression Model

- Proponemos modelar la influencia de **HRV** sobre **HRT** de la siguiente forma:

$$TS_i = f(HRV_i \text{ indices}) + \varepsilon_i; \quad i = 1, \dots, N \quad (1)$$

donde  $\varepsilon_i$  es el resíduo del  $i$ -ésimo término,  $HRV_i$  indices son índices del dominio del tiempo para el  $i$ -ésimo VPC, y  $N$  es el número total de VPCs disponibles.



# Métodos

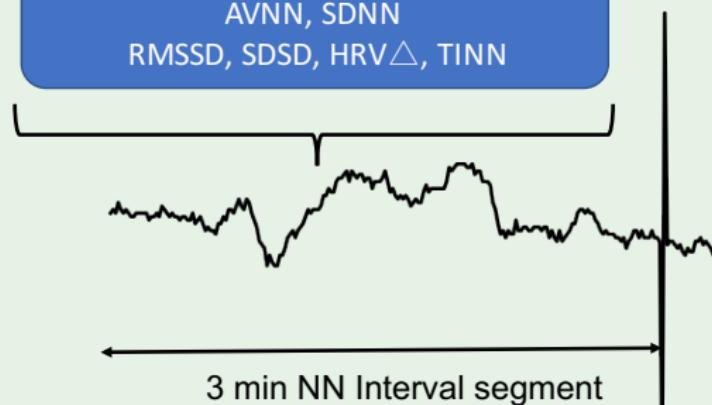
## HRT Boosted Regression Model

- Proponemos modelar la influencia de **HRV** sobre **HRT** de la siguiente forma:

$$TS_i = f(HRV_i \text{ indices}) + \varepsilon_i; \quad i = 1, \dots, N \quad (1)$$

donde  $\varepsilon_i$  es el resíduo del  $i$ -ésimo término,  $HRV_i$  indices son índices del dominio del tiempo para el  $i$ -ésimo VPC, y  $N$  es el número total de VPCs disponibles.

HRV Time Domain Indices:  
AVNN, SDNN  
RMSSD, SDSD, HRV $\triangle$ , TINN



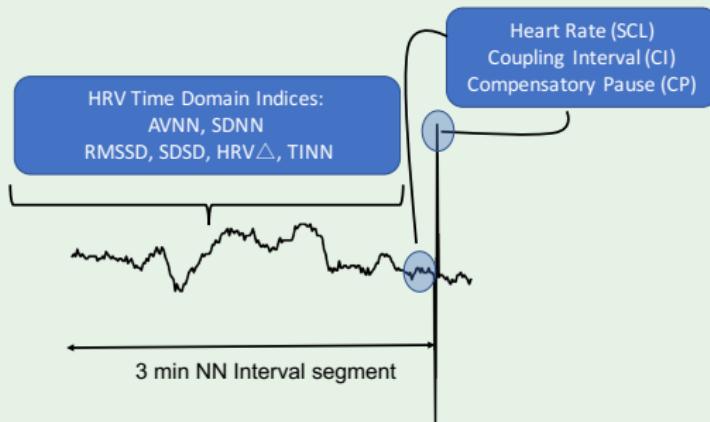
# Métodos

## HRT Boosted Regression Model

- Proponemos modelar la influencia de **HRV** sobre **HRT** de la siguiente forma:

$$TS_i = f(HRV_i \text{ indices}) + \varepsilon_i; \quad i = 1, \dots, N \quad (1)$$

donde  $\varepsilon_i$  es el resíduo del  $i$ -ésimo término,  $HRV_i$  indices son índices del dominio del tiempo para el  $i$ -ésimo VPC, y  $N$  es el número total de VPCs disponibles.



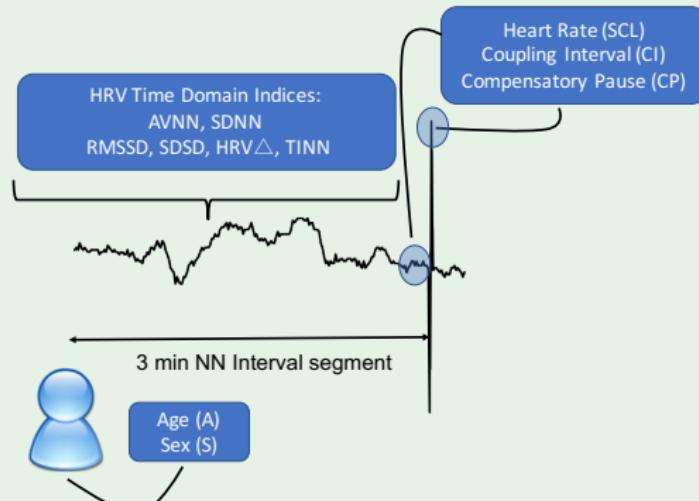
# Métodos

## HRT Boosted Regression Model

- Proponemos modelar la influencia de **HRV** sobre **HRT** de la siguiente forma:

$$TS_i = f(HRV_i \text{ indices}) + \varepsilon_i; \quad i = 1, \dots, N \quad (1)$$

donde  $\varepsilon_i$  es el resíduo del  $i$ -ésimo término,  $HRV_i$  indices son índices del dominio del tiempo para el  $i$ -ésimo VPC, y  $N$  es el número total de VPCs disponibles.



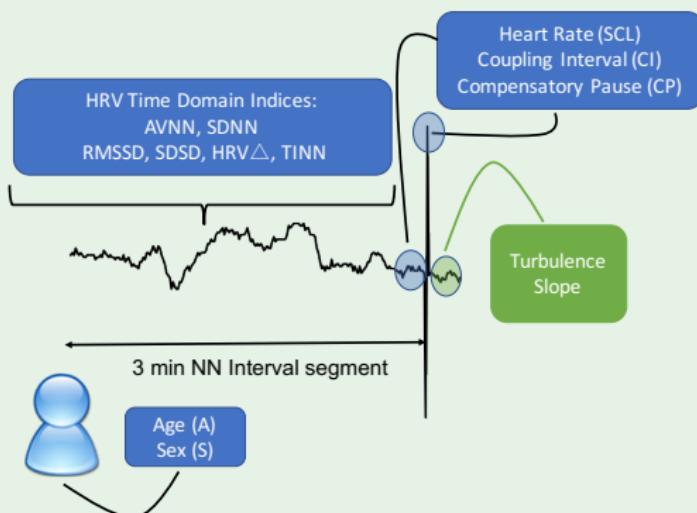
# Métodos

## HRT Boosted Regression Model

- Proponemos modelar la influencia de **HRV** sobre **HRT** de la siguiente forma:

$$TS = \hat{f}(S_{cl}, C_i, C_p, A, S, A_{vnn}S_{dnn}, r_{mssd}, S_{dsd}, HRV_{\Delta}, T_{inn}) \quad (2)$$

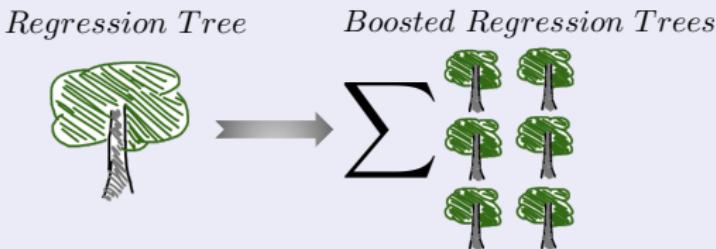
para cada VPC individual (válido) en un Holter de 24 horas.



# Métodos

## HRT Boosted Regression Model

- Cómo estimamos  $\hat{f}$ ?
- Proponemos planterlo como un problema de *regresión*, y resolverlo utilizando **Boosted Regression Trees**.
- **BRT** es una aproximación de agregación para construir un modelo de regresión mediante la combinación de varios árboles binarios, pequeños y simples.
- La principal idea es aprender **poco a poco**, en vez de aprender de una vez con un modelo complejo.



# Métodos

## Inferencia usando el modelo BRT

- **Partial Dependence Plots:** estudio el efecto de una variable en la variable respuesta.
- **Relative Importance:** Mide la contribución de cada variable explicativa en el modelo.
- **Selección de las características relevantes:** Identificar las características estadísticamente significativas utilizando validación cruzada.

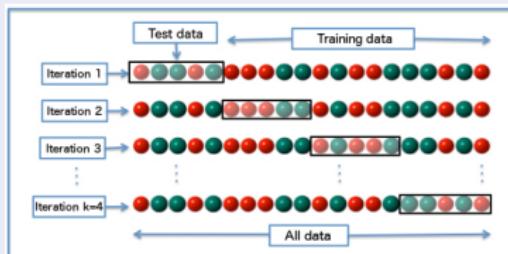
# Métodos

## Inferencia usando el modelo BRT

- **Partial Dependence Plots:** estudio el efecto de una variable en la variable respuesta.
- **Relative Importance:** Mide la contribución de cada variable explicativa en el modelo.
- **Selección de las características relevantes:** Identificar las características estadísticamente significativas utilizando validación cruzada.

## Selección de características usando Validación Cruzada

- **Proceso iterativo:** Modelos con una característica (variable explicativa) menos en cada iteración. Las características ordenadas por importancia relativa.
- Se evalua el **error de cada modelo** utilizando **cross-validation**.
- **El modelo con menor error sólo tiene las características estadísticamente relevantes.**



# Contents

1 1. Introducción

2 2. Métodos

3 3. Database

4 4. Results

5 5. Conclusiones & Trabajo Futuro

## Base de datos de Infarto de Miocardio

- 61 pacientes que han sufrido un Infarto de Miocardio (IM) del Hospital Universitario Virgen de Arrixaca (Murcia).
- Un Holter 24 horas para cada paciente.
- $64 \pm 9$  años, 18 mujeres.

## Partición de la Base de Datos

### Bajo-Riesgo

- $TS > 2.5 \text{ & } TO < 0$

### Alto-Riesgo

- $TS < 2.5 \text{ & } TO > 0$

# Contents

1 1. Introducción

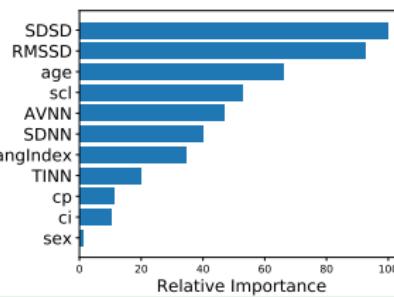
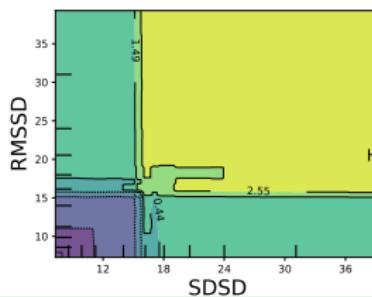
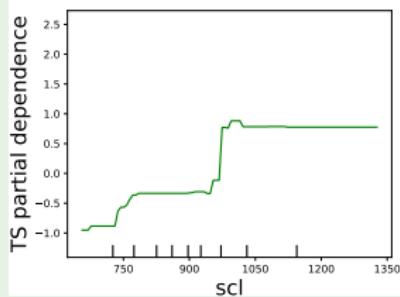
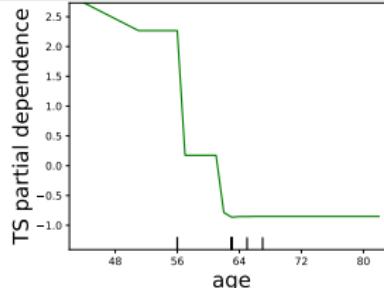
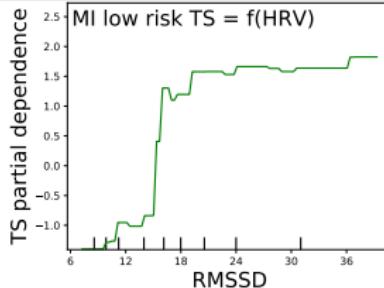
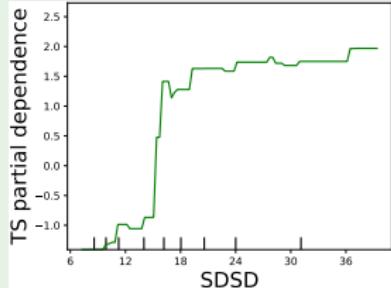
2 2. Métodos

3 3. Database

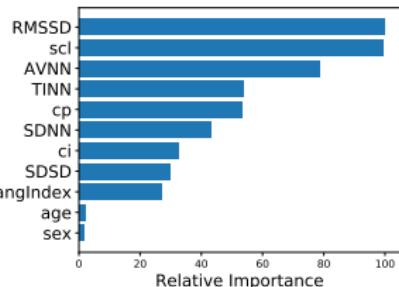
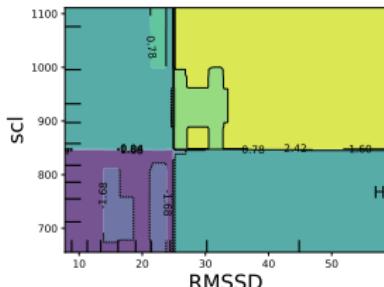
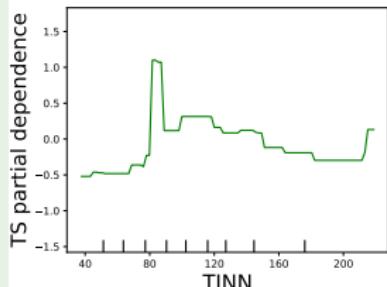
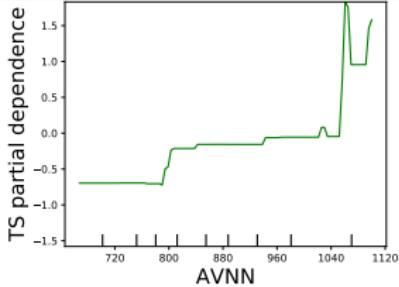
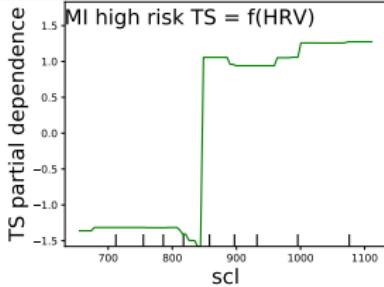
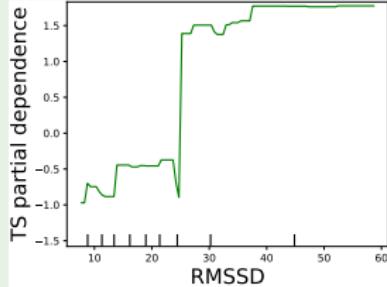
4 4. Results

5 5. Conclusiones & Trabajo Futuro

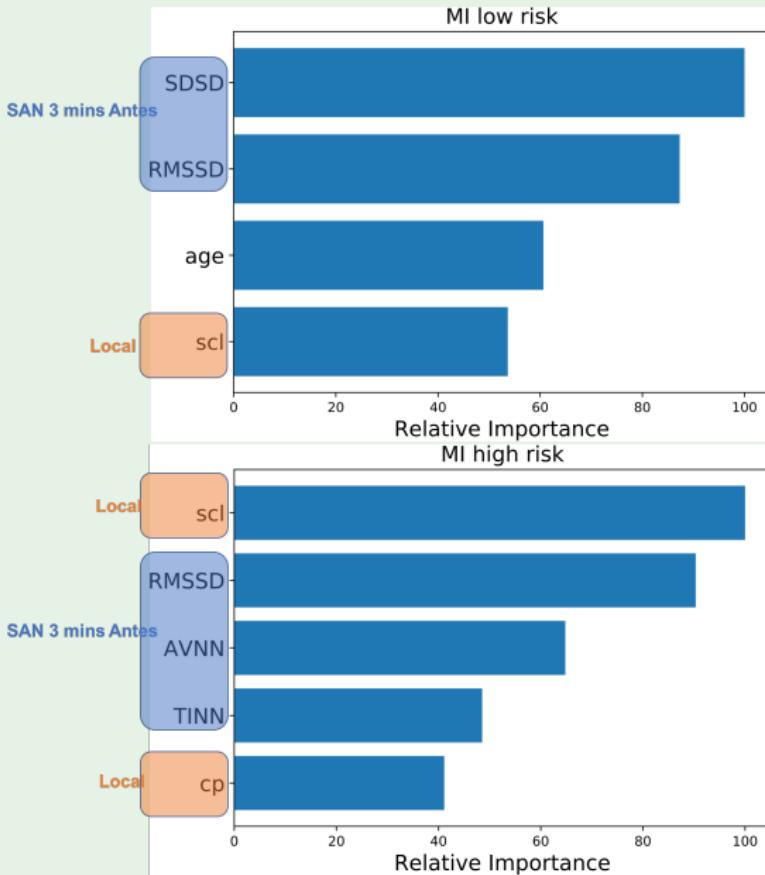
# Results - Bajo Riesgo



# Results - Alto Riesgo



# Results - Selección de Características



# Contents

1 1. Introducción

2 2. Métodos

3 3. Database

4 4. Results

5 5. Conclusiones & Trabajo Futuro

# Conclusiones & Trabajo Futuro

## Conclusiones

- El método propuesto permite modelar la relación entre **HRV** y **HRT** en VPC individuales.

# Conclusiones & Trabajo Futuro

## Conclusiones

- El método propuesto permite modelar la relación entre **HRV** y **HRT** en VPC individuales.
- El estado del **SNA** en los 3 minutos previos al VPC fue la característica más importante para explicar la respuesta del **HRT** en pacientes de **bajo riesgo**.



# Conclusiones & Trabajo Futuro

## Conclusiones

- El método propuesto permite modelar la relación entre **HRV** y **HRT** en VPC individuales.
- El estado del **SNA** en los 3 minutos previos al VPC fue la característica más importante para explicar la respuesta del **HRT** en pacientes de **bajo riesgo**.
- Sin embargo, la condición local (**SCL**, **CP**) justo antes del VPC, fueron las características más importante para explicar la respuesta **HRT** en pacientes de **alto riesgo**.



# Conclusiones & Trabajo Futuro

## Conclusiones

- El método propuesto permite modelar la relación entre **HRV** y **HRT** en VPC individuales.
- El estado del **SNA** en los 3 minutos previos al VPC fue la característica más importante para explicar la respuesta del **HRT** en pacientes de **bajo riesgo**.
- Sin embargo, la condición local (**SCL, CP**) justo antes del VPC, fueron las características más importantes para explicar la respuesta **HRT** en pacientes de **alto riesgo**.

## Trabajo Futuro

- Incluir más índices de HRV: **Dominio de la Frecuencia, Índices Nolineales.**

# Conclusiones & Trabajo Futuro

## Conclusiones

- El método propuesto permite modelar la relación entre **HRV** y **HRT** en VPC individuales.
- El estado del **SNA** en los 3 minutos previos al VPC fue la característica más importante para explicar la respuesta del **HRT** en pacientes de **bajo riesgo**.
- Sin embargo, la condición local (**SCL, CP**) justo antes del VPC, fueron las características más importantes para explicar la respuesta **HRT** en pacientes de **alto riesgo**.

## Trabajo Futuro

- Incluir más índices de HRV: **Dominio de la Frecuencia, Índices Nolineales.**
- Crear una combinación de características para eliminar la multicolinealidad: **Principal Component Analysis, Partial Least Squares Regression.**

# Conclusiones & Trabajo Futuro

## Conclusiones

- El método propuesto permite modelar la relación entre **HRV** y **HRT** en VPC individuales.
- El estado del **SNA** en los 3 minutos previos al VPC fue la característica más importante para explicar la respuesta del **HRT** en pacientes de **bajo riesgo**.
- Sin embargo, la condición local (**SCL, CP**) justo antes del VPC, fueron las características más importantes para explicar la respuesta **HRT** en pacientes de **alto riesgo**.

## Trabajo Futuro

- Incluir más índices de HRV: **Dominio de la Frecuencia, Índices Nolineales.**
- Crear una combinación de características para eliminar la multicolinealidad: **Principal Component Analysis, Partial Least Squares Regression.**
- Pensar en una forma de incorporar esta información para caracterizar el riesgo de muerte cardíaca.

# **Modelado de la Influencia de la Variabilidad de Frecuencia Cardíaca en la Turbulencia del Ciclo Cardíaco**

**O Barquero Pérez, S. Cantero, R Goya Esteban,  
JL Rojo Álvarez, A García Alberola**

**Universidad Rey Juan Carlos**  
Departamento de Teoría de la Señal y Comunicaciones



December 1, 2017

# BRT method

- BRT is an ensemble approach to build a regression model combining several *small*, simple, decision trees. The main idea is to learn slowly.
- The BRT estimation is obtained sequentially as follow:
  - ①  $\hat{f}(x) = 0$ , training data is  $r_i = TS_i$  for all the  $i$  VPC-tachograms.
  - ② For  $b = 1, 2, \dots, B$  repeat:
    - ① Fit a small tree  $\hat{f}^b$  using training data:  $\{x_i, r_i\}$ .
    - ② Update  $\hat{f}$  by adding a shrunken version of the new small tree:  $\hat{f} \leftarrow \hat{f} + \lambda \hat{f}^b$
    - ③ Update the residuals,  $r_i \leftarrow r_i - \lambda \hat{f}^b$
  - ③ Finally output the BRT model:  $\hat{f} = \sum_{b=1}^B \lambda \hat{f}^b$

# BRT method

